

UNIVERSIDAD DE LOS ANDES



OceanWatch Analytics

Informe de avance consolidado: Entrega 1

Decisiones de diseño y cumplimiento de requisitos

Soluciones Intensivas en Datos (2026-20), MINE 4213

Integrantes

Juan Sebastián Corredor Sánchez - 202014956

Karina Marita Aranguren Espinoza - 202326292

Estefanía Quijano García - 202311445

Bogotá, Colombia

25 de septiembre de 2026

Índice

1	Resumen ejecutivo	2
2	Avance por requisito	2
3	Las 7 decisiones centrales (D-01 a D-07)	4
4	Hallazgos que respaldan las decisiones	5
5	Dificultades técnicas y cómo se resolvieron	6
6	Técnicas y herramientas utilizadas	6
7	Resultados de las cinco preguntas de negocio	7
8	Pendiente de confirmar con el profesor	7
9	Estado y próximos pasos	8
10	Nota sobre trazabilidad	8

1 Resumen ejecutivo

- El trabajo organiza mensajes AIS de NOAA y Marine Cadastre en un lakehouse para OceanWatch Analytics.
- El corpus cubre del 01 al 07 de junio de 2023 y usa los enlaces oficiales `.zip`.
- Cada archivo se descargó, verificó, extrajo a un Volume de Unity Catalog y leyó con un `StructType` explícito de 17 columnas.
- El conteo observado fue **60,533,559 posiciones**, frente a los ~150 millones estimados en el enunciado.
- Esta diferencia de volumen quedó registrada como hallazgo y no alteró el alcance de los siete archivos solicitados.
- La ejecución se hizo en Databricks Free Edition serverless con Spark 4.2.0. El prototipo local usa PySpark 4.2.0.
- El lakehouse usa el catálogo provisional `oceanwatch_g06` y los esquemas `landing`, `reference` y `analytics`.
- La entrega cubre ingesta, perfilamiento, cinco preguntas de negocio, almacenamiento óptimo y gobernanza de Unity Catalog.
- El repositorio reúne notebooks exportados, decisiones, fuentes, evidencias, bitácora y reglas para excluir artefactos pesados.
- Los seis requisitos de la Entrega 1 están documentados como completos. Quedan decisiones docentes no bloqueantes para una eventual corrección.

Fuentes: `docs/evidencia_ingesta_databricks_7_dias.md`, `docs/decisiones_pendientes_de_confirmar.md`, `BITACORA.md` y `README.md`.

2 Avance por requisito

1. Ingesta

- Los siete CSV se validaron localmente y en Databricks con el mismo `StructType`, encabezado estricto y unión por nombre sin columnas faltantes.
- En Databricks, la unión final dio **60,533,559 filas**, igual al conteo local. No hubo diferencias de esquema ni encoding. Cada ZIP tuvo tamaño y SHA-256 observados, mientras que el CSV extraído se verificó con lectura y conteo.
- La primera ejecución completa del 01 de junio confirmó 8,808,904 filas, sin diferencia frente a local. Spark reportó versión 4.2.0.
- Evidencia: `docs/evidencia_ingesta_local_7_dias.md`, `docs/evidencia_ingesta_databricks_7_dias.md` y notebook `01_ingesta_ais`.

2. Perfilamiento de calidad

- El corpus completo se perfiló sin `cache()` ni `persist()`: 60,533,559 posiciones y 31,871 MMSI únicos antes de D-07.

- El análisis cuantificó nulos, sentinelas AIS, coordenadas y velocidades fuera de rango, MMSI no conformes, duplicados y exclusiones para Haversine.
- D-04 dejó **60,369,975 pares elegibles** para trayectorias después de excluir gaps no positivos, gaps mayores de dos horas y velocidades implícitas mayores de 60 kn.
- Evidencia: docs/evidencia_perfilamiento_calidad_databricks.md y notebook 02_perfilamiento_calidad.

3. Preguntas de negocio

- Las cinco preguntas, de 03a a 03e, se respondieron con planes Photon, reglas D-04 y D-07 cuando correspondía, y evidencia individual.
- Los resultados cubren cardinalidad diaria, tráfico por tipo AIS, distancia Haversine por buque, concentración H3 con WPI y permanencia semanal con visitantes.
- Evidencia: docs/resumen_preguntas_negocio.md, docs/evidencia_pregunta_03a.md a docs/evidencia_pregunta_03e.md y notebook 03_preguntas_negocio.

4. Almacenamiento óptimo

- El propósito elegido fue recuperar historial temporal por MMSI y tiempo, representativo de 03c y 03e.
- La comparación usó el mismo conjunto D-07 de **60,482,276 filas** como Parquet en Volume y Delta administrada con CLUSTER BY (MMSI, BaseDateTime).
- Para la consulta selectiva por MMSI, Delta alcanzó 4 archivos frente a 57 de Parquet. OPTIMIZE no reescribió archivos, por lo que no se le atribuyen variaciones posteriores de tiempo.
- Evidencia: docs/evidencia_almacenamiento_pre_optimize.md, docs/resumen_requisito_4_almacenamiento.md y notebook 04_almacenamiento_optimizado.

5. Gobernanza

- Se verificaron los comentarios, la jerarquía y la metadata de oceanwatch_g06, sus esquemas, los Volumes landing.raw_ais, reference.world_port_index, analytics.benchmark_files y la tabla Delta oficial.
- La evidencia reporta la propiedad efectiva del usuario del workspace Free Edition y cero grants explícitos en catálogo, esquema analytics y tabla Delta.
- Evidencia: docs/evidencia_gobernanza.md y notebook 05_gobernanza_documentacion.

6. Repositorio y reproducibilidad

- El repositorio contiene los seis notebooks en formato legible, documentación de decisiones, fuentes y evidencias, bitácora, entorno local reproducible y reglas de exclusión para datos crudos, artefactos Spark, entornos y el reporte local de validación.
- README.md define el orden de ejecución, la convención de notebooks, el entorno local y las restricciones serverless relevantes.

- Evidencia: `README.md`, `BITACORA.md`, `.gitignore` y `notebooks`
`00_configuracion_unity_catalog` a `05_gobernanza_documentacion`.

3 Las 7 decisiones centrales (D-01 a D-07)

Esta sección resume qué se decidió y por qué cada decisión responde a lo que pide el enunciado. No repite el detalle técnico completo de los notebooks.

ID	Decisión	Por qué cumple lo pedido
D-01	Usar los 7 CSV tal como llegan: 60,533,559 registros, no los ~150M que estimaba el enunciado.	El requisito 1 pide procesar los 7 días oficiales, no una cifra objetivo. El conteo se validó de principio a fin (Databricks igual a local, diferencia 0), así que la diferencia de volumen es un hallazgo declarado, no un error de procesamiento.
D-02	Descargar los ZIP oficiales dentro del notebook, verificando ZIP y CSV como artefactos separados (HTTP 200, tamaño, SHA-256, <code>is_zipfile</code> para el ZIP; esquema y conteo para el CSV).	El requisito exige ingesta documentada con reintentos y verificación de integridad. Verificar ambos artefactos por separado es honesto: no se puede comparar el hash de algo comprimido con algo descomprimido, y NOAA no publica checksum oficial, así que se registra el observado.
D-03	Asociar el centroide de una celda H3 (resolución 8) a un punto del World Port Index si están a ≤ 2 km, y reportar también el resultado a 1 km y 5 km.	La pregunta de negocio sobre dónde se concentra el tráfico necesita una definición operativa de cercanía a un puerto. 2 km es un umbral conservador y defendible. Mostrar la sensibilidad en 1, 2 y 5 km demuestra que el resultado no se ajusta eligiendo el radio que más convenga.
D-04	Al calcular distancia recorrida por buque, solo sumar pares de posiciones consecutivas con $0 < \text{gap} \leq 2\text{h}$ y velocidad implícita ≤ 60 kn.	Sin este filtro, un salto de GPS o una desconexión larga infla la distancia con un tramo que el buque nunca recorrió. El umbral se justifica con evidencia física (60 kn es un límite razonable para tráfico marítimo) y se reporta cuántos pares quedan fuera.
D-05	Para el requisito de almacenamiento, no juzgar por tiempos de ejecución (sub segundo y ruidosos) sino por bytes y archivos leídos (vía <code>plan de ejecución y _metadata.file_path</code>).	Es literalmente lo que pide el requisito 4: demostrar la mejora con evidencia, no con una sensación de mayor rapidez. Los archivos leídos (4 frente a 57) son una métrica estable que no depende del calentamiento de la sesión.
D-06	Organizar Unity Catalog en tres esquemas por función (<code>landing</code> , <code>reference</code> , <code>analytics</code>), no en capas <code>bronze</code> , <code>silver</code> y <code>gold</code> .	El enunciado excluye explícitamente el pipeline por capas del alcance de esta entrega. Usar esquemas por función cumple el requisito de gobernanza sin afirmar una arquitectura medallion que aún no corresponde.

ID	Decisión	Por qué cumple lo pedido
D-07	Deduplicar filas exactas (las 17 columnas) de forma transversal, pero exigir MMSI de 9 dígitos solo en las métricas que agrupan o identifican buques.	El requisito de calidad pide cuantificar y tratar problemas de datos con criterio, no eliminar todo lo raro. Los duplicados exactos (0.0023%) no aportan nada en ningún caso. Los MMSI no conformes (0.0824%) solo distorsionan cuando se cuenta o rastrea un buque específico, así que se excluyen ahí y se conservan donde se agregan posiciones por tipo o celda.

Cómo estas decisiones cubren cada requisito de la rúbrica

- **Ingesta (15%)**: cubierta por D-01 y D-02. Se descarga desde la fuente oficial, con reintentos, y se verifica integridad de dos artefactos distintos (ZIP y CSV) en vez de un solo chequeo superficial.
- **Exploración y calidad (20%)**: cubierta por D-07 y el tratamiento de los sentinelas AIS (SOG=102.3, Heading=511, COG=360). Se cuantifica cada problema y se decide, con razón explícita, cuándo excluirlo y cuándo no.
- **Preguntas de negocio (25%)**: cubierta por D-03 y D-04, que son las reglas que hacen defendibles las respuestas espaciales (03d) y de distancia (03c). Además, en 03a se comparó conteo exacto y aproximado, y se justificó con el error observado (hasta 9.21%) por qué se prefirió el exacto.
- **Almacenamiento óptimo (25%)**: cubierta por D-05. Se declara un propósito de consulta (historial por buque), se elige Delta con `CLUSTER BY (MMSI, BaseDateTime)` sobre Parquet, y se demuestra la mejora con archivos leídos (4 frente a 57), reportando también, con honestidad, que `OPTIMIZE` no tuvo efecto porque la tabla ya estaba clustered desde la escritura.
- **Gobernanza (10%)**: cubierta por D-06. La organización del catálogo tiene una razón de diseño explícita (función, no capas) y se documenta con comentarios y metadatos verificables vía `DESCRIBE ... EXTENDED`.
- **Repositorio y bitácora (5%)**: cada decisión, de D-01 a D-07, queda trazada en `BITACORA.md` con su evidencia asociada en `docs/`, que es justamente lo que pide este requisito.

4 Hallazgos que respaldan las decisiones

- El corpus real tiene **60,533,559** posiciones, frente a los ~150M que enunciaba el ejercicio. Es una diferencia de volumen registrada, no una estimación recalculada.
- `Status` es nulo en el **100%** de las filas con `TransceiverClass=B` y no nulo en clase A: es ausencia **estructural** del transpondedor, no un error a corregir. Respalda el criterio de D-07 de no eliminar datos sin motivo.
- Los sentinelas AIS son masivos: `Heading=511` aparece en **33,535,628** filas (55.4001%), `COG=360` en **10,291,131** (17.0007%) y `SOG=102.3` en **159,987** (0.2643%). Confirma por qué no se pueden tratar como error aislado sino como valores de dato no disponible del estándar AIS.

- `approx_count_distinct` tuvo diferencias de **1.10% a 9.21%** frente al conteo exacto (RSD 0.05 por defecto, con ~ 20 mil MMSI por día). Esa variación concreta es la evidencia detrás de preferir `countDistinct` en 03a.
- El control físico del primer lugar en distancia recorrida fue consistente: JUSTIN PAUL ECKSTEIN hizo **5,770.92 km** en una semana, equivalente a ≈ 18.55 kn sostenidos, con solo 8 pares excluidos de 2,865 válidos, lo que descarta que la cifra venga de un salto erróneo.
- Solo **2 de las 10** celdas H3 con más tráfico estuvieron a ≤ 2 km de un puerto WPI. A 5 km se asocian 5, lo que cambia la clasificación de tres celdas adicionales. Es la evidencia numérica detrás de reportar la sensibilidad de D-03 en vez de un solo umbral fijo.
- Los 5,964 visitantes de un solo día se concentraron en el 01 de junio (1,326) y el 07 de junio (1,244), un efecto de borde de la ventana de 7 días y no un patrón de fin de semana. *Pleasure craft* y *Sailing* suman 65.5265% de ellos.
- OPTIMIZE no agregó ni removi6 archivos porque la tabla Delta ya estaba organizada por liquid clustering desde la escritura.

5 Dificultades técnicas y cómo se resolvieron

Dificultad	Resolución aplicada
<code>input_file_name()</code> no está disponible en serverless con Unity Catalog.	Se usa <code>_metadata.file_path</code> para identificar el origen de cada fila y para la evidencia de archivos leídos del requisito 4.
Free Edition rechazó USING PARQUET para tabla administrada.	Parquet se conservó como línea base en el Volume gobernado <code>analytics.benchmark_files</code> . Delta fue la tabla administrada de producción, la única opción viable en la plataforma.
La librería Python <code>h3</code> no debía asumirse persistente entre sesiones serverless.	El análisis espacial (03d) usa funciones H3 nativas de Databricks, ejecutadas por Photon. <code>h3==4.5.0</code> quedó solo para el prototipo local.
El ZIP descargado y el CSV extraído tienen hashes distintos por ser comprimido y descomprimido.	Se verifican por separado: tamaño y SHA-256 observado del ZIP, y esquema más conteo de filas del CSV, en vez de forzar una comparación que no tiene sentido.
Un DataFrame lazy reutilizado en varias salidas de 03e produjo varias ramas <code>Scan csv</code> en el plan.	Se dejó así y se documentó en el plan. No se materializó una tabla intermedia ni se usó caché fuera de lo permitido por la plataforma.

6 Técnicas y herramientas utilizadas

- PySpark y Apache Spark 4.2.0 en Databricks Free Edition serverless, con planes ejecutados por Photon donde se documenta.
- Esquema AIS explícito, lectura CSV, unión estricta, reintentos HTTP, comprobación de ZIP y SHA-256 observado.
- Funciones Window por MMSI y fórmula de Haversine para trayectorias; `countDistinct` y `approx_count_distinct` con HyperLogLog para comparar cardinalidad.

- H3 nativo de Databricks para la grilla de resolución 8 y broadcast del World Port Index.
- Delta Lake administrado con liquid clustering `CLUSTER BY (MMSI, BaseDateTime)`, Parquet de línea base en Volume y `OPTIMIZE` medido.
- Unity Catalog: catálogo, esquemas, Volumes, comentarios, `DESCRIBE ... EXTENDED y SHOW GRANTS`.
- Git y GitHub como mecanismo de versionado del código y la documentación. `.gitignore` excluye datos y artefactos reproducibles locales.

7 Resultados de las cinco preguntas de negocio

Pregunta	Resultado documentado
03a. Buques distintos por día	Entre 19,597 y 21,086 MMSI válidos diarios. Se usa <code>countDistinct</code> ; el aproximado tuvo una diferencia de 1.10% a 9.21%.
03b. Tipos con más tráfico	Towing (código 31) lidera con 16,557,760 posiciones, seguido de Pleasure craft (código 37) con 14,476,457 . El sentinela <code>SOG=102.3</code> se excluye de sus promedios.
03c. Mayor distancia	JUSTIN PAUL ECKSTEIN (MMSI 367638030, tipo 31) acumuló 5,770.92 km . D-04 aceptó 60,369,977 pares en la base D-07 de esta pregunta.
03d. Concentración	La celda <code>8828d555a1ffff</code> registró 235,260 posiciones. A 2 km, 2 de las 10 celdas líderes se asociaron a un puerto WPI.
03e. Permanencia y visitantes	12,656 de 31,780 MMSI válidos transmitieron los siete días (39.8238%). Hubo 5,964 visitantes de un solo día.

Detalle y planes de ejecución: `docs/resumen_preguntas_negocio.md` y `docs/evidencia_pregunta_03a.md` a `docs/evidencia_pregunta_03e.md`.

8 Pendiente de confirmar con el profesor

Estas decisiones se tomaron para avanzar sin bloquear el proyecto, pero siguen abiertas a corrección docente:

- **D-01:** el conteo real (60.5M) frente a los ~ 150 M que estimaba el enunciado.
- **D-02:** usar los enlaces `.zip` del enunciado en vez de la distribución `.csv.zst` que NOAA ofrece actualmente.
- **D-03:** si el profesor prefiere otra definición de cercanía a puerto distinta al buffer de 2 km sobre centroide H3.
- **D-04:** si los umbrales de 2 h y 60 kn son los que espera el curso, o si deben recalibrarse.
- **D-07:** la naturaleza de los MMSI no conformes (86 IDs cortos, 5 largos). Quedan excluidos de métricas por buque porque no hay fuente externa para clasificarlos, no porque se haya decidido que son inválidos.
- **Identificador de catálogo:** si el equipo conserva `g06` como nombre definitivo o lo sustituye antes del cierre.

9 Estado y próximos pasos

La Entrega 1 está documentada como completa en sus seis requisitos. Las decisiones pendientes listadas arriba no bloquean el avance actual, pero quedan sujetas a confirmación docente antes de una eventual corrección.

Según el alcance ya documentado, la Entrega 2 debe reutilizar el perfilamiento de calidad de esta entrega como insumo para definir y justificar reglas de tratamiento. Cualquier ajuste posterior debe conservar trazabilidad en `BITACORA.md` y actualizar la decisión afectada, sin reescribir la evidencia histórica.

10 Nota sobre trazabilidad

Cada decisión tiene su documento de evidencia correspondiente en `docs/` (por ejemplo `evidencia_perfilamiento_calidad_databricks.md` para D-04 y D-07, o `evidencia_almacenamiento_pre_optimize.md` para D-05). Si alguna decisión cambia, incluidas las pendientes de la sección anterior, el ajuste debe quedar registrado en `BITACORA.md` sin sobrescribir la evidencia histórica.