

Decisiones de diseño: OceanWatch Analytics (Entrega 1)

Este documento resume las decisiones que se tomaron para la Entrega 1 y por qué cada una responde a lo que pide el enunciado. No repite el detalle técnico completo de los notebooks; se enfoca en qué se decidió y por qué cumple el requisito correspondiente.

Las 7 decisiones centrales (D-01 a D-07)

ID	Decisión	Por qué cumple lo pedido
D-01	Usar los 7 CSV tal como llegan: 60,533,559 registros, no los ~150M que estimaba el enunciado.	El requisito 1 pide procesar los 7 días oficiales, no una cifra objetivo. El conteo se validó end-to-end (Databricks = local, diferencia 0), así que la diferencia de volumen es un hallazgo declarado, no un error de procesamiento.
D-02	Descargar los ZIP oficiales dentro del notebook, verificando ZIP y CSV como artefactos separados (HTTP 200, tamaño, SHA-256, <code>is_zipfile</code> para el ZIP; esquema + conteo para el CSV).	El requisito exige ingesta documentada con reintentos y verificación de integridad. Verificar ambos artefactos por separado es honesto: no se puede comparar el hash de algo comprimido con algo descomprimido, y NOAA no publica checksum oficial, así que se registra el observado.
D-03	Asociar el centroide de una celda H3 (resolución 8) a un punto del World Port Index si están a ≤ 2 km, y reportar también el resultado a 1 km y 5 km.	La pregunta de negocio “¿dónde se concentra el tráfico?” necesita una definición operativa de “cerca de un puerto”. 2 km es un umbral conservador y defendible; mostrar la sensibilidad (1/2/5 km) demuestra que el resultado no se maquilla eligiendo el radio que más convenga.
D-04	Al calcular distancia recorrida por buque, solo sumar pares de posiciones consecutivas con $0 < \text{gap} \leq 2\text{h}$ y velocidad implícita ≤ 60 kn.	Sin este filtro, un salto de GPS o una desconexión larga infla la distancia con un tramo que el buque nunca recorrió. El umbral se justifica con evidencia física (60 kn es un límite razonable para tráfico marítimo) y se reporta cuántos pares quedan fuera.
D-05	Para el requisito de almacenamiento, no juzgar por tiempos de ejecución (subsegundo, ruidosos) sino por bytes y archivos leídos (vía plan de ejecución y <code>_metadata.file_path</code>).	Es literalmente lo que pide el requisito 4: Demostrar la mejora con evidencia, no con una sensación de “se sintió más rápido”. Los archivos leídos (4 vs 57) son una métrica estable que no depende del calentamiento de la sesión.
D-06	Organizar Unity Catalog en tres esquemas por función (<code>landing</code> , <code>reference</code> , <code>analytics</code>), no en capas <code>bronze/silver/gold</code> .	El enunciado excluye explícitamente el pipeline por capas del alcance de esta entrega. Usar esquemas por función cumple el requisito de gobernanza sin afirmar una arquitectura medallion que aún no corresponde.

ID	Decisión	Por qué cumple lo pedido
D-07	Deduplicar filas exactas (las 17 columnas) de forma transversal, pero exigir MMSI de 9 dígitos solo en las métricas que agrupan o identifican buques.	El requisito de calidad pide cuantificar y tratar problemas de datos con criterio, no borrar todo lo raro. Los duplicados exactos (0.0023%) no aportan nada en ningún caso; los MMSI no conformes (0.0824%) sólo distorsionan cuando se cuenta o rastrea un buque específico, así que se excluyen ahí y se conservan donde se agregan posiciones por tipo o celda.

Cómo estas decisiones cubren cada requisito de la rúbrica

- **Ingesta (15%)**: Cubierta por D-01 y D-02. Se descarga desde la fuente oficial, con reintentos, y se verifica integridad de dos artefactos distintos (ZIP y CSV) en vez de un solo chequeo superficial.
- **Exploración y calidad (20%)**: Cubierta por D-07 y el tratamiento de los sentinelas AIS (SOG=102.3, Heading=511, COG=360). Se cuantifica cada problema y se decide, con razón explícita, cuándo excluirlo y cuándo no.
- **Preguntas de negocio (25%)**: Cubierta por D-03 y D-04, que son las reglas que hacen defendibles las respuestas espaciales (03d) y de distancia (03c). Además, en 03a se comparó conteo exacto vs aproximado y se justificó con el error observado (hasta 9.21%) por qué se prefirió el exacto.
- **Almacenamiento óptimo (25%)**: Cubierta por D-05. Se declara un propósito de consulta (historial por buque), se elige Delta con `CLUSTER BY (MMSI, BaseDateTime)` sobre Parquet, y se demuestra la mejora con archivos leídos (4 vs 57), reportando también, con honestidad, que `OPTIMIZE` no tuvo efecto porque la tabla ya estaba clustered desde la escritura.
- **Gobernanza (10%)**: Cubierta por D-06. La organización del catálogo tiene una razón de diseño explícita (función, no capas) y se documenta con comentarios y metadatos verificables vía `DESCRIBE ... EXTENDED`.
- **Repositorio y bitácora (5%)**: Cada decisión D-01 a D-07 queda trazada en `BITACORA.md` con su evidencia asociada en `docs/`, que es justamente lo que pide este requisito.

Dificultades técnicas y cómo se resolvieron

Dificultad	Resolución aplicada
<code>input_file_name()</code> no está disponible en serverless con Unity Catalog.	Se usa <code>_metadata.file_path</code> para identificar el origen de cada fila y para la evidencia de archivos leídos del requisito 4.
Free Edition rechazó <code>USING PARQUET</code> para tabla administrada.	Parquet se conservó como línea base en el Volume gobernado <code>analytics.benchmark_files</code> ; Delta fue la tabla administrada de producción (única opción viable en la plataforma).
La librería Python <code>h3</code> no debía asumirse persistente entre sesiones serverless.	El análisis espacial (03d) usa funciones H3 nativas de Databricks, ejecutadas por Photon; <code>h3==4.5.0</code> quedó solo para el prototipo local.

Dificultad	Resolución aplicada
El ZIP descargado y el CSV extraído tienen hashes distintos (comprimido vs descomprimido).	Se verifican por separado: Tamaño y SHA-256 observado del ZIP, y esquema + conteo de filas del CSV, en vez de forzar una comparación que no tiene sentido.
Un DataFrame lazy reutilizado en varias salidas de 03e produjo varias ramas <code>Scan csv</code> en el plan.	Se dejó así y se documentó en el plan; no se materializó una tabla intermedia ni se usó caché fuera de lo permitido por la plataforma.

Hallazgos que respaldan las decisiones (con cifras)

- **Status** es nulo en el **100%** de las filas con **TransceiverClass=B** y no nulo en clase A: es ausencia **estructural** del transpondedor, no un error a corregir (respalda el criterio de D-07 de no borrar por borrar).
- Los sentinelas AIS son masivos: **Heading=511** aparece en **33,535,628** filas (55.4001%), **COG=360** en **10,291,131** (17.0007%) y **SOG=102.3** en **159,987** (0.2643%). Confirma por qué no se pueden tratar como error aislado sino como valores “no disponible” del estándar AIS.
- **approx_count_distinct** tuvo diferencias de **1.10% a 9.21%** frente al conteo exacto (RSD 0.05 por defecto, con ~20 mil MMSI/día); esa variación concreta es la evidencia detrás de preferir **countDistinct** en 03a.
- El control físico del #1 en distancia recorrida fue consistente: JUSTIN PAUL ECKSTEIN hizo **5,770.92 km** en una semana (≈ 18.55 kn sostenidos), con solo 8 pares excluidos de 2,865 válidos, lo que descarta que la cifra venga de un salto erróneo.
- Solo **2 de las 10** celdas H3 con más tráfico estuvieron a ≤ 2 km de un puerto WPI; a 5 km se asocian 5. Es la evidencia numérica detrás de reportar la sensibilidad de D-03 en vez de un solo umbral fijo.
- Los 5,964 visitantes de un solo día se concentraron en el 01-jun (1,326) y el 07-jun (1,244), un efecto de borde de la ventana de 7 días y no un patrón de fin de semana. *Pleasure craft* y *Sailing* suman 65.5265% de ellos.

Pendiente de confirmar

Estas decisiones se tomaron para avanzar sin bloquear el proyecto, pero siguen abiertas a corrección:

- **D-01:** El conteo real (60.5M) frente a los ~150M que estimaba el enunciado.
- **D-02:** Usar los enlaces **.zip** del enunciado en vez de la distribución **.csv.zst** que NOAA ofrece actualmente.
- **D-03:** Si el profesor prefiere otra definición de “corresponde a puerto” distinta al buffer de 2 km sobre centroide H3.
- **D-04:** Si los umbrales de 2 h y 60 kn son los que espera el curso, o si deben recalibrarse.
- **D-07:** La naturaleza de los MMSI no conformes (86 IDs cortos, 5 largos). Quedan excluidos de métricas por buque porque no hay fuente externa para clasificarlos, no porque se haya

decidido que son inválidos.

- **Identificador de catálogo:** Si el equipo conserva `g07` como nombre definitivo o lo sustituye antes del cierre.

Nota sobre trazabilidad

Cada decisión tiene su documento de evidencia correspondiente en `docs/` (por ejemplo `evidencia_perfilamiento_calidad_databricks.md` para D-04 y D-07, o `evidencia_almacenamiento_pre_optimize.md` para D-05). Si alguna decisión cambia, incluidas las pendientes de arriba, el ajuste debe quedar registrado en `BITACORA.md` sin sobrescribir la evidencia histórica.