Proyecto Final

Soluciones Intensivas en Datos (2026-20)

Entrega 2

OceanWatch Analytics: el lakehouse del tráfico marítimo

Proyecto final · 30% de la nota del curso · Grupos de 3 · Dos entregas

---

1. Contexto

Ustedes son el equipo de datos de **OceanWatch Analytics**, el operador analítico que las autoridades portuarias y las navieras contratan para entender el tráfico marítimo: qué buques pasan, por dónde, a qué velocidad y cuánto tiempo permanecen en puerto.

Los buques mercantes transmiten su posición de forma continua mediante el **AIS** (Automatic Identification System): identificador, posición, velocidad, rumbo y características del buque, mensaje a mensaje. La NOAA publica todo ese tráfico para las aguas de Estados Unidos en archivos diarios.

En la **primera fase** del proyecto exploraron esos datos, respondieron las preguntas que hace el negocio y los dejaron almacenados de forma óptima para el propósito acordado. En la **segunda fase** construirán el pipeline completo: ingestión en streaming, procesamiento por capas con control de calidad, orquestación automatizada y la consola de visualización.

2. Los datos

- **Fuente oficial:** AIS Data de Marine Cadastre (NOAA). Un archivo zip por día, con un CSV de posiciones adentro. Documentación del dataset y del estándar AIS: https://hub.marinecadastre.gov/pages/vesseltraffic
- **Columnas de referencia** (verifican las exactas de sus archivos): `MMSI` (identificador del buque), `BaseDateTime`, `LAT`, `LON`, `SOG` (velocidad sobre el fondo, nudos), `COG` (rumbo), `Heading`, `VesselName`, `IMO`, `CallSign`, `VesselType` (código), `Status`, `Length`, `Width`, `Draft`, `Cargo`, `TransceiverClass`.
- **Recursos complementarios:**
  - **World Port Index** (puertos del mundo): disponible desde la misma página del dataset (https://hub.marinecadastre.gov/pages/vesseltraffic); también se acepta cualquier otra fuente de puertos, citada en el README.
  - Los códigos de `VesselType` corresponden a las categorías de tipo de buque del estándar AIS; su descripción está en la documentación del dataset.

- Estos son **datos crudos de sensores**: traen problemas reales de la fuente. Detectarlos, cuantificarlos y documentarlos hace parte del trabajo.
- Para el análisis espacial pueden usar una **grilla regular**: celdas **H3** (con la librería `h3`) o simplemente redondear latitud/longitud a una rejilla fija. Cualquiera de las dos sirve si la justifican.

3. Entrega 2 — tiempo real, capas y orquestación

60% del proyecto (18% de la nota del curso) · Workspace institucional

Con el corpus extendido y el feed diario de llegadas construyen el proceso completo: **ingestión en streaming, procesamiento por capas con control de calidad, orquestación automatizada y la consola de visualización**.

#	Requisito	%
1	**Ingesta en streaming:** el feed diario de archivos que llegan entra con Structured Streaming (checkpoints, manejo de duplicados por buque y timestamp, tolerancia a fallos demostrada)	15
2	**Proceso por capas con calidad como compuerta:** implementar patrones de ingeniería de datos para asegurar la calidad de la información: capa bronce (crudo inmutable) → plata (aplicación de compuertas de calidad o expectations: coordenadas en rango y en el agua, velocidades plausibles, identificadores bien formados, deduplicación; cuarentena y tabla de métricas de calidad) → oro (el modelo del negocio: trayectorias diarias por buque, presencia en puertos, matrices de tráfico por celda espacial y hora). Un registro no llega a oro si no pasa las compuertas	15
3	**Orquestación:** job end-to-end con tareas y dependencias, parámetros (la fecha del día), reintentos, monitoreo y ejecución programada demostrada	20
4	**Consola de visualización:** tablero (Databricks Dashboards o Power BI) o aplicación desplegada, alimentado por la capa oro: mapa de intensidad de tráfico por celda, ranking de puertos, buques en puerto, anomalías del día	15
5	**Gobernanza:** esquemas con permisos por rol, linaje y documentación del contrato de datos de la capa oro	10
6	**ML con MLflow:** pronóstico de arribos portuarios por día y puerto, o detección de anomalías de velocidad: ingeniería de características, experimento trackeado y modelo registrado. Demostrar la integración de ML dentro de un pipeline reproducible, no maximizar la precisión predictiva.	10
7	**Repositorio y bitácora** actualizados	5

#	Requisito	%
8	**Sustentación final** en la última clase	10

4. Bono opcional: Interoperabilidad con Delta Sharing (+5% extra)

Implementar un mecanismo de compartición de datos utilizando **Delta Sharing (Open Sharing)** para publicar las tablas de la capa oro desde el workspace institucional de Databricks Enterprise y consumirlas desde un workspace independiente de **Databricks Free Edition**. A partir de los datos compartidos, deberán construir en Free Edition las visualizaciones solicitadas para la consola de OceanWatch Analytics, demostrando que los resultados del pipeline pueden ser utilizados desde un entorno externo sin necesidad de exportar manualmente los datos ni duplicar todo el dataset.

5. Recomendaciones

- **Patrones de calidad en streaming:** implementen la calidad como un proceso continuo y automatizado mediante compuertas o **expectations**; los registros no válidos deben enrutarse a una tabla de cuarentena con la causa documentada, sin detener el flujo del streaming.
- **Enfoque de ML:** el objetivo central es demostrar la integración de ML con un **pipeline reproducible** (extracción de variables desde el Lakehouse, experimentos trackeados con MLflow y registro del modelo en Unity Catalog / Model Registry), **no maximizar la precisión predictiva**. Mantengan la arquitectura del modelo simple y manejable.
- **Para la consola de la Entrega 2** recomendamos **Databricks Dashboards** (no exige licencias adicionales). Power BI requiere Power BI Desktop y la conectividad se valida en la semana 10; una aplicación propia también se acepta, **siempre que quede desplegada y accesible**, no como script local.
- Toda decisión técnica se demuestra con **evidencia** (planes de ejecución, archivos leídos), no con opiniones. "Lo hice porque es más rápido" no es un argumento.
- **Trabajen de forma incremental:** cada clase aporta una pieza del proyecto y la bitácora es la evidencia de ese avance continuo.

6. Reglas del juego

- **Grupos de 3 estudiantes.** En la sustentación final cada integrante debe poder explicar cualquier parte del proyecto.
- La entrega se hace con el **Bloque Neon.**
- **La calidad de forma y contenido** (documentación, estándares, redacción) hace parte de la calificación.